

Wstęp do uczenia maszynowego - praca domowa 1

Przemysław Kania
Numer indeksu: 333063
Grupa: GR 3

27 października 2025

1 Analiza danych

Do rozwiązania poniższej pracy domowej mamy do dyspozycji dwa zbiory danych: "X.csv" oraz "y.csv", posiadające tą samą liczbę wierszy. Zawierają one jednak komórki NaN, które należy usunąć razem z całym wierszem, aby algorytm był w pełni sprawny. Łączymy je więc w jedną tabelę, a następnie upewniamy się, które wiersze konkretnie posiadają w sobie wartości NaN i te wiersze usuwamy. Na koniec rozdzielamy czystą ramkę ponownie, aby otrzymać w pełni funkcjonalne zbiory danych "X" i "y", na których będziemy operować. W międzyczasie za pomocą komendy `.info()` za każdym razem sprawdzana zostaje zawartość utworzonych tabel. Po tej obróbce danych zostają wygenerowane zbiór treningowy i testowy w proporcji 8:2 z parametrem `random_state=NUMER_INDEKSU`.

2 Eksperyment

Po podzieleniu zbiorów na treningowe i testowe nadszedł czas na eksperyment badający miarę AUC drzewa decyzyjnego. Wykorzystując 10-krotną krosvalidację na danych treningowych oraz parametr `random_state=NUMER_INDEKSU`, w zależności od poniższych hiperparametrów i wybranych dla nich wartości, badamy problem:

- kryterium podziału (`criterion=["gini","entropy"]`),
- głębokość drzewa (`max_depth=[1,3,5,7,9,11,13]`),
- minimalna liczba obserwacji w liściu (`min_samples_leaf=[2,4,8,14,22,32,44]`)
- `splitter=["best","random"]` (jako hiperparametr, który jest badany pod kątem ewentualnej poprawy jakości badanego modelu)

Następnie dla każdego modelu, biorąc pod uwagę pierwsze trzy rodzaje hiperparametrów, obliczany zostaje średni wynik AUC z walidacji krzyżowej na zbiorze testowym. Dane zebrano w tabelę i posortowano według malejącej wartości AUC. Jej pierwsze pięć wierszy prezentuje się następująco:

criterion	max_depth	min_samples_leaf	AUC_mean	AUC_std	AUC_test
entropy	5	8	0.932807	0.033224	0.966956
entropy	5	4	0.937008	0.030368	0.960726
gini	11	14	0.939701	0.023859	0.959823
gini	13	14	0.939701	0.023859	0.959823
gini	9	14	0.939701	0.023859	0.959823

Jak można zauważyć najlepszy model uzyskano dla parametrów:

- `criterion = "entropy"`,
- `max_depth = 5`,
- `min_samples_leaf = 8`,
- `AUC_test = 0.966956`.

Badając dodatkowo zachowanie drzew z hiperparametrem `splitter` otrzymano następującą tabelę:

criterion	max_depth	min_samples_leaf	splitter	AUC_test
entropy	5	8	best	0.966956
entropy	5	4	best	0.960726
gini	7	14	best	0.959823
gini	9	14	best	0.959823
gini	13	14	best	0.959823

Można zauważyć, że po dodaniu do modelu hiperparametru `splitter`, ten najlepszy nie uległ zmianie i w dalszym ciągu przoduje, a zmiany następują dopiero dla innych, jednak nie mają one jeszcze aż tak dobrej wartości `AUC_test` żeby wybić się na najlepsze miejsce. Można więc przypuszczać, że dla innych danych hiperparametrów modelu, ten najlepszy rzeczywiście się zmieni.

3 Analiza jakości predykcyjnej modelu

Dla wybranego najlepszego modelu oraz dla modelu z domyślnymi hiperparametrami na danych treningowych oraz testowych wyznaczamy macierze pomyłek, dokładność, czułość i precyzję oraz krzywą ROC i wartość AUC:

Tabela 1: Macierz pomyłek dla najlepszego modelu

	Predykacja 0	Predykacja 1
Rzeczywiste 0	71	7
Rzeczywiste 1	2	69

Tabela 2: Macierz pomyłek dla domyślnego modelu

	Predykacja 0	Predykacja 1
Rzeczywiste 0	69	9
Rzeczywiste 1	6	65

Tabela 3: Wartości dokładności, czułości i precyzji

Dokładność (najlepszy model)	0.9395973154362416
Czułość (najlepszy model)	0.971830985915493
Precyzja (najlepszy model)	0.9078947368421053
Dokładność (domyślny model)	0.8993288590604027
Czułość (domyślny model)	0.9154929577464789
Precyzja (domyślny model)	0.8783783783783784

Rysunek 1: Krzywe ROC dla modelu najlepszego i domyślnego




Tabela 4: Wartość AUC

Wartość AUC (najlepszy model)	0.966955579631636
Wartość AUC (domyślny model)	0.9000541711809318

Analizując wyniki poszczególnych miar i macierze pomyłek oraz krzywą ROC widać, że najlepszy model ma większą zdolność predykcyjną niż model domyślny.

4 Wpływ rozmiaru próbki treningowej na jakość predykcyjną modelu


Znów dla obydwu modeli przeprowadzamy badania. Tym razem polegające na losowym wyborze 5%, 10%, 25%, 50%, 75%, 90%, 95% danych treningowych oraz ocenę miary AUC. Wyniki prezentują się następująco:

Tabela 5: Model najlepszy

Rozmiar	AUC testowy	AUC treningowy
5%	0.8431	0.8809
10%	0.8615	0.9181
25%	0.8748	0.9242
50%	0.8683	0.9111
75%	0.9163	0.9367
90%	0.9053	0.9431
95%	0.9005	0.9418

Tabela 6: Model domyślny

Rozmiar	AUC testowy	AUC treningowy
5%	0.7987	1.00
10%	0.8503	1.00
25%	0.8316	1.00
50%	0.8706	1.00
75%	0.9005	1.00
90%	0.9035	1.00
95%	0.9545	1.00



Analizując uzyskane wyniki oraz wykres można zauważyć że wraz ze wzrostem rozmiaru zbioru treningowego zwiększa się jakość predykcyjna rozważanego modelu. Nie zwiększa się jednak ona liniowo lecz nieregularnie ale jednak daje lepsze wyniki.