

# Wstęp do uczenia maszynowego - praca domowa 2

Przemysław Kania  
Numer indeksu: 333063  
Grupa: GR 3

21 listopada 2025

## 1 Analiza danych

Do rozwiązania poniższej pracy domowej mamy do dyspozycji dwa zbiory danych: "df\_X.csv" (1537 wierszy i 22 kolumny) oraz "df\_y.csv" (1537 wierszy i 2 kolumny). Zawierają one jednak komórki NaN, które należy usunąć razem z całym wierszem, aby algorytm był w pełni sprawny. Łączymy je więc w jedną tabelę, a następnie upewniamy się, które wiersze konkretnie posiadają w sobie wartości NaN i te wiersze usuwamy. Na koniec rozdzielamy czystą ramkę ponownie, aby otrzymać w pełni funkcjonalne zbiory danych "df\_X" i "df\_y", na których będziemy operować. W międzyczasie za pomocą komendy `.info()` za każdym razem sprawdzana zostaje zawartość utworzonych tabel. Po tej obróbce danych zostają wygenerowane zbiór treningowy i testowy w proporcji 8:2 z parametrem `random_state=NUMER_INDEKSU`.

## 2 Część 1

W tej części przygotowujemy cztery jak najlepsze modele regresji logistycznej. Są to:

1. model regresji logistycznej;
2. model regresji logistycznej z regularyzacją L1,
3. model regresji logistycznej z regularyzacją L2,
4. model regresji logistycznej z karą *elasticnet* (jest to technika regresji liniowej, która łączy regularyzację L1 i L2).

Do procedury optymalizacji modeli stosujemy listy funkcję `GridSearchCV`, hiperparametry `C=[0.001,0.01,0.1,1,10,100,1000]` do modelu 2,3,4 oraz `l1_ratio=[0.1,0.5,0.9]` do modelu 4. Po przeprowadzeniu testów najlepsze modele mają parametry:

|                                     |                     |
|-------------------------------------|---------------------|
| Najlepsze C dla modelu 1            | C=1 (domyślne)      |
| Najlepsze C dla modelu 2            | C=0.1               |
| Najlepsze C dla modelu 3            | C=1000              |
| Najlepsze C i l1_ratio dla modelu 4 | C=0.1, l1_ratio=0.9 |


Jakość obu modeli oceniamy na podstawie zbioru treningowego oraz zbioru testowego. Otrzymaliśmy dla nich poniższe metryki (dokładność, czułość, precyzję, wartość AUC) oraz krzywe ROC:

Tabela 1: dla zbioru treningowego

| model                             | dokładność | czułość  | precyzja | AUC      |
|-----------------------------------|------------|----------|----------|----------|
| regresja logistyczna              | 0.858515   | 0.878536 | 0.855754 | 0.940959 |
| regresja logistyczna (L1)         | 0.861135   | 0.885191 | 0.855305 | 0.943746 |
| regresja logistyczna (L2)         | 0.857642   | 0.878536 | 0.854369 | 0.941027 |
| regresja logistyczna (elasticnet) | 0.863755   | 0.890183 | 0.856000 | 0.943253 |

Tabela 2: dla zbioru testowego

| model                             | dokładność | czułość  | precyzja | AUC      |
|-----------------------------------|------------|----------|----------|----------|
| regresja logistyczna              | 0.853659   | 0.875000 | 0.852564 | 0.940741 |
| regresja logistyczna (L1)         | 0.871080   | 0.881579 | 0.875817 | 0.942641 |
| regresja logistyczna (L2)         | 0.853659   | 0.875000 | 0.852564 | 0.940741 |
| regresja logistyczna (elasticnet) | 0.867596   | 0.881579 | 0.870130 | 0.942690 |



Zestawienie współczynników coefs i intercepts w postaci tabel znajduje się na końcu raportu. Jest ono przedstawione dla obydwu zbiorów, treningowego oraz testowego.

### 3 Część 2

Definiujemy następujący model: `SVM_model = SVC(kernel="linear", C=1, probability=True, random_state=333063)`. Identyfikacja jak w części 1 otrzymujemy metryki oraz krzywe ROC:

Tabela 3: dla zbioru treningowego

| metryka     | wartość            |
|-------------|--------------------|
| dokładność  | 0.868995633187773  |
| czułość     | 0.8868552412645591 |
| precyzja    | 0.8666666666666667 |
| wartość AUC | 0.9473732504649114 |

Tabela 4: dla zbioru testowego

| metryka     | wartość            |
|-------------|--------------------|
| dokładność  | 0.8397212543554007 |
| czułość     | 0.875              |
| precyzja    | 0.83125            |
| wartość AUC | 0.9389619883040936 |





Tabela 5: Zestawienie wartości współczynników coefs oraz intercepts wybranych modeli regresji logistycznej (M1-model zwykły, M2-model l1, M3-model l2, M4-model elasticnet)

dla zbioru treningowego

| Idx                 | M1      | M2      | M3      | M4      |
|---------------------|---------|---------|---------|---------|
| <i>Intercepts</i>   |         |         |         |         |
| 0                   | -0.0210 | 0.0000  | -0.0209 | 0.0213  |
| <i>Coefficients</i> |         |         |         |         |
| 0                   | 2.0241  | 1.4818  | 2.0240  | 1.4720  |
| 1                   | -1.2133 | -0.7855 | -1.2131 | -0.7694 |
| 2                   | 1.0249  | 0.7112  | 1.0248  | 0.7124  |
| 3                   | 0.7402  | 0.5206  | 0.7402  | 0.5242  |
| 4                   | -1.0200 | -0.6979 | -1.0200 | -0.6990 |
| 5                   | 1.2181  | 0.8624  | 1.2180  | 0.8624  |
| 6                   | 2.7314  | 1.8814  | 2.7309  | 1.8324  |
| 7                   | -0.2928 | 0.0000  | -0.2918 | 0.0000  |
| 8                   | 0.1346  | 0.0371  | 0.1346  | 0.0448  |
| 9                   | -0.0400 | 0.0000  | -0.0401 | 0.0000  |
| 10                  | 0.0456  | 0.0000  | 0.0455  | 0.0000  |
| 11                  | 0.0060  | 0.0000  | 0.0060  | 0.0000  |
| 12                  | -1.3799 | 0.0000  | -1.3750 | 0.0000  |
| 13                  | 0.1206  | 0.0000  | 0.1206  | 0.0065  |
| 14                  | -0.0062 | 0.0000  | -0.0062 | 0.0000  |
| 15                  | -0.0744 | 0.0000  | -0.0744 | 0.0000  |
| 16                  | 0.9028  | 0.0000  | 0.8998  | 0.0000  |
| 17                  | -0.0309 | 0.0000  | -0.0309 | 0.0000  |
| 18                  | 0.0701  | 0.0000  | 0.0701  | 0.0000  |
| 19                  | -1.5954 | 0.0000  | -1.5897 | 0.0000  |
| 20                  | 0.0162  | 0.0000  | 0.0163  | 0.0044  |
| 21                  | -0.1103 | -0.2367 | -0.1104 | -0.2666 |
| 22                  | 0.0934  | 0.0000  | 0.0934  | 0.0000  |
| 23                  | 0.0430  | 0.0000  | 0.0430  | 0.0000  |
| 24                  | 0.0485  | 0.0000  | 0.0485  | 0.0000  |
| 25                  | -0.0908 | 0.0000  | -0.0907 | 0.0000  |

dla zbioru testowego

| Idx                 | M1      | M2      | M3      | M4      |
|---------------------|---------|---------|---------|---------|
| <i>Intercepts</i>   |         |         |         |         |
| 0                   | -0.0210 | 0.0000  | -0.0209 | 0.0213  |
| <i>Coefficients</i> |         |         |         |         |
| 0                   | 2.0241  | 1.4819  | 2.0240  | 1.4719  |
| 1                   | -1.2133 | -0.7857 | -1.2131 | -0.7693 |
| 2                   | 1.0249  | 0.7112  | 1.0248  | 0.7124  |
| 3                   | 0.7402  | 0.5205  | 0.7402  | 0.5242  |
| 4                   | -1.0200 | -0.6979 | -1.0200 | -0.6990 |
| 5                   | 1.2181  | 0.8624  | 1.2180  | 0.8624  |
| 6                   | 2.7314  | 1.8818  | 2.7309  | 1.8323  |
| 7                   | -0.2928 | 0.0000  | -0.2918 | 0.0000  |
| 8                   | 0.1346  | 0.0371  | 0.1346  | 0.0448  |
| 9                   | -0.0400 | 0.0000  | -0.0401 | 0.0000  |
| 10                  | 0.0456  | 0.0000  | 0.0455  | 0.0000  |
| 11                  | 0.0060  | 0.0000  | 0.0060  | 0.0000  |
| 12                  | -1.3799 | 0.0000  | -1.3750 | 0.0000  |
| 13                  | 0.1206  | 0.0000  | 0.1206  | 0.0065  |
| 14                  | -0.0062 | 0.0000  | -0.0062 | 0.0000  |
| 15                  | -0.0744 | 0.0000  | -0.0744 | 0.0000  |
| 16                  | 0.9028  | 0.0000  | 0.8998  | 0.0000  |
| 17                  | -0.0309 | 0.0000  | -0.0309 | 0.0000  |
| 18                  | 0.0701  | 0.0000  | 0.0701  | 0.0000  |
| 19                  | -1.5954 | 0.0000  | -1.5897 | 0.0000  |
| 20                  | 0.0162  | 0.0000  | 0.0163  | 0.0045  |
| 21                  | -0.1103 | -0.2366 | -0.1104 | -0.2666 |
| 22                  | 0.0934  | 0.0000  | 0.0934  | 0.0000  |
| 23                  | 0.0430  | 0.0000  | 0.0430  | 0.0000  |
| 24                  | 0.0485  | 0.0000  | 0.0485  | 0.0000  |
| 25                  | -0.0908 | 0.0000  | -0.0907 | 0.0000  |